

Relatório Técnico: Mobilidade Urbana Inteligente

João Vitor Dantas Barbosa Pedro Emilio Castro Lemos
Matheus Gualter Silva Resende Paulo Daniel Forti da Fonseca
Pedro Henrique Lopes Duarte

09 de Julho de 2026

Resumo

Este relatório consolida as quatro etapas do projeto de Mobilidade Urbana Inteligente com dados de corridas da Uber em Nova York. O fluxo partiu dos 20.000 primeiros registros do arquivo de maio de 2014, removeu 780 duplicatas e manteve 19.220 registros válidos. A Etapa 1 tratou datas, variáveis temporais e normalização; a Etapa 2 analisou distribuições, outliers, correlações, PCA e vizinhança; a Etapa 3 comparou algoritmos de clusterização e escolheu K-Means com $K = 4$; e a Etapa 4 minerou padrões frequentes, regras de associação e anomalias por distância. Os resultados indicam pico às 17h, concentração de 43,63% dos registros entre 14h e 19h, baixa redundância entre variáveis, ausência de redução dimensional útil por PCA sem perda relevante, clusters estáveis entre sementes e padrões temporais fortes associados aos clusters finais.

1 Introdução

Registros de mobilidade urbana permitem estudar quando e onde a demanda por transporte se concentra. Neste projeto, o problema foi analisado como um fluxo completo de ciência de dados: preparação, exploração, modelagem, visualização e extração final de padrões interpretáveis.

A pergunta que orientou o trabalho foi: *como latitude, longitude, hora e dia ajudam a descrever padrões espaço-temporais de corridas da Uber no recorte analisado?* O objetivo não foi prever demanda futura, mas caracterizar a amostra com métricas transparentes, comparar alternativas de agrupamento e transformar os resultados em conclusões reprodutíveis.

2 Dados e Base Analítica

A base original foi `ubernymaio14.csv`, correspondente ao conjunto “Uber Pickups in New York City”. O arquivo completo contém 652.435 linhas, mas o projeto trabalhou com os 20.000 primeiros registros para manter o processamento adequado ao escopo da disciplina e aos notebooks. Após a remoção de duplicatas, o arquivo tratado `ubernymaio14_tratado.csv` ficou com 19.220 registros.

Tabela 1: Resumo da base tratada na Etapa 1.

Item	Valor
Registros lidos do arquivo original	20.000
Duplicatas removidas	780
Registros válidos após tratamento	19.220
Período coberto	01/05/2014 00:02 a 16/05/2014 20:10
Base operacional presente	B02512
Variáveis usadas na modelagem	Lat, Lon, Hour, Day
Valores ausentes no tratado	0

A coluna `Date/Time` foi convertida para tipo temporal, permitindo criar `Hour` e `Day`. Em seguida, `Lat`, `Lon` e `Hour` foram normalizadas por Min-Max Scaling. A variável `Day` foi preservada na escala 1–16 no arquivo tratado, e por isso as etapas baseadas em distância aplicaram `StandardScaler` antes da modelagem.

Tabela 2: Estatísticas descritivas das variáveis numéricas tratadas.

Variável	Mín.	Q1	Mediana	Média	Q3	Desv. pad.	Outliers IQR
Lat	0,000	0,382	0,408	0,404	0,426	0,045	855
Lon	0,000	0,278	0,284	0,286	0,290	0,026	1.856
Hour	0,000	0,435	0,652	0,623	0,783	0,237	0
Day	1,000	4,000	8,000	8,407	13,000	4,666	0

Os possíveis outliers foram identificados pelo critério $Q1 - 1,5 \times IQR$ e $Q3 + 1,5 \times IQR$. Eles foram mantidos porque os extremos aparecem nas coordenadas geográficas, podendo representar corridas reais em regiões menos frequentes, e não erros evidentes.

3 Metodologia

A metodologia foi organizada como um pipeline de quatro etapas encadeadas. Cada etapa recebeu como entrada o artefato produzido na etapa anterior, de modo que o projeto saísse do dado bruto, passasse pela análise exploratória, gerasse grupos por algoritmos de aprendizado não supervisionado e terminasse com uma interpretação consolidada dos padrões encontrados.

Etapla 1 – preparação da base analítica. A primeira etapa carregou os 20.000 primeiros registros de `ubernymaio14.csv`, verificou valores ausentes, removeu duplicatas, converteu `Date/Time` para tipo temporal e criou `Hour` e `Day`. Em seguida, `Lat`, `Lon` e `Hour` foram normalizadas com Min-Max Scaling. O resultado foi o arquivo `ubernymaio14_tratado.csv`, usado como entrada das etapas seguintes. Essa etapa também definiu uma decisão importante: os extremos geográficos foram preservados, pois não havia evidência suficiente de erro e eles poderiam representar corridas reais em regiões menos frequentes.

Etapla 2 – análise exploratória e diagnóstico dos atributos. A segunda etapa avaliou estatísticas descritivas, histogramas, boxplots, distribuição espacial, distribuição por base, correlações e PCA. Pearson mediu associação linear, enquanto Spearman mediu associação monotônica. O limiar $r \geq 0,80$ foi adotado como sinal de redundância forte; nenhum par atingiu esse valor. O PCA foi aplicado após padronização para verificar se as quatro variáveis poderiam ser resumidas em menos dimensões. Além da variância explicada, foi avaliado o impacto de diferentes representações na vizinhança: para 2.000 consultas, os 10 vizinhos mais próximos no espaço `Lat/Lon` foram comparados com os vizinhos obtidos no espaço completo padronizado e no PCA. As métricas usadas foram sobreposição@10, Jaccard médio e correlação de Spearman entre distâncias.

Etapla 3 – modelagem não supervisionada. A terceira etapa usou `Lat`, `Lon`, `Hour` e `Day` para clusterização. Antes dos algoritmos, as variáveis foram padronizadas com `StandardScaler`, porque `Day` estava em escala diferente das demais. Foram testados K-Means, Agglomerative Clustering e DBSCAN. O K-Means foi avaliado para K de 2 a 10 por inércia, silhouette, Davies-Bouldin, Calinski-Harabasz e estabilidade entre sementes. A silhouette mede coesão e separação, com valores maiores indicando grupos mais separados. Davies-Bouldin compara dispersão interna e separação entre grupos, sendo melhor quando menor. Calinski-Harabasz cresce quando a separação entre clusters é alta em relação à dispersão interna. ARI e NMI compararam rótulos gerados com diferentes sementes; valores próximos de 1 indicam estabilidade.

Etapla 4 – interpretação, regras e anomalias. A quarta etapa interpretou os clusters por mineração de padrões frequentes e detecção de anomalias. O Apriori foi aplicado sobre itens categóricos derivados de `cluster_kmeans`, período do dia, faixa do dia do mês, faixa de latitude e faixa de longitude. O suporte mínimo foi 8%, a confiança mínima 55%, o lift mínimo interpretável 1,05 e o tamanho máximo dos itemsets foi 3. Suporte mede frequência do padrão; confiança mede a probabilidade do consequente dado o antecedente; lift mede quanto a regra é mais forte do que seria esperado ao acaso. Para anomalias, calculou-se a distância média aos 5 vizinhos mais próximos no espaço `Lat`, `Lon`, `Hour`, `Day` padronizado, marcando como anômalos os registros acima do percentil 97,5%.

Tabela 3: Encadeamento das etapas do projeto.

Etapa	Entrada principal	Saída ou resultado principal
1. Tratamento	ubernymaio14.csv	ubernymaio14_tratado.csv, com 19.220 registros, Hour, Day e variáveis normalizadas.
2. Exploração	ubernymaio14_tratado.csv	Diagnóstico de distribuição temporal, outliers, correlações, PCA e impacto na vizinhança.
3. Algoritmos	Base tratada com Lat, Lon, Hour, Day padronizados	Clusters finais em etapa3/clusters_etapa3.csv, usando K-Means com $K = 4$.
4. Interpretação	etapa3/clusters_etapa3.csv	Padrões frequentes, regras de associação e anomalias em arquivos CSV da Etapa 4.

Tabela 4: Decisões metodológicas consolidadas.

Decisão	Justificativa
Uso de Lat, Lon, Hour e Day	Essas variáveis representam a dimensão espaço-temporal disponível no conjunto. A coluna Base foi mantida como informação de origem, mas não entrou na modelagem porque é constante no recorte tratado.
Manutenção dos outliers geográficos	Os pontos extremos de latitude e longitude não foram removidos porque podem indicar corridas reais em regiões menos densas. Removê-los reduziria a capacidade de detectar grupos pequenos e anomalias espaciais.
Padronização antes dos algoritmos	Day estava em escala 1–16, enquanto Lat, Lon e Hour estavam normalizadas. A padronização evitou que a escala numérica definisse artificialmente a importância dos atributos.
Escolha do K-Means final	O K-Means com $K = 4$ foi escolhido por rodar no conjunto completo, apresentar estabilidade muito alta entre sementes e gerar grupos interpretáveis. Métricas melhores em amostras foram tratadas como evidência complementar, não como substituição direta.
Uso de Apriori na Etapa 4	A clusterização gera grupos numéricos; o Apriori transforma esses grupos em associações legíveis entre cluster, período do dia, faixa do mês e localização. Isso facilita explicar o comportamento encontrado.
Anomalias por vizinhança	A distância média aos 5 vizinhos identifica registros isolados em relação ao padrão local. O percentil 97,5% foi escolhido para destacar uma fração pequena e interpretável da amostra.

4 Resultados Exploratórios

A distribuição temporal foi a evidência mais forte da exploração. O pico ocorreu às 17h, com 1.622 registros, equivalente a 8,44% da amostra. O intervalo de 14h a 19h concentrou 8.385 registros, ou 43,63% do total. Em contraste, a madrugada de 0h a 5h concentrou 1.163 registros, apenas 6,05%.


**Figura 1:** Quantidade de registros por hora extraída de Date/Time.

Tabela 5: Correlações, PCA e preservação de vizinhança.

Análise	Resultado	Interpretação
Maior Pearson	Lat-Lon: 0,147	Sem redundância linear forte.
Maior Spearman	Lat-Lon: 0,496	Relação monotônica moderada entre coordenadas.
PCA PC1 + PC2	54,58% da variância	Útil para visualização, insuficiente para substituir os atributos.
Componentes para 90%	4 componentes	Não houve redução dimensional relevante sem perda de informação.
Completo padronizado	Sobreposição@10 de 3,13%	Incluir tempo altera fortemente a noção de proximidade espacial.
PCA 2D	Sobreposição@10 de 1,98%	A projeção simplifica a visualização, mas distorce vizinhos locais.

5 Clusterização

O K-Means com $K = 4$ foi escolhido como solução final por equilibrar qualidade, estabilidade e simplicidade. Embora $K = 5$ tenha obtido silhouette ligeiramente maior, sua estabilidade caiu para ARI mínimo de 0,7623 entre sementes. O $K = 7$ foi estável, mas aumentou a complexidade interpretativa por ganho pequeno.

Tabela 6: Métricas de seleção de K no K-Means.

K	Inércia	Silhouette	Davies-Bouldin	Calinski-Harabasz
2	62.789,65	0,2250	1,7244	4.312,70
3	53.073,36	0,2367	1,3716	4.310,03
4	44.619,60	0,2568	1,1588	4.631,12
5	39.190,73	0,2679	1,0437	4.619,72
7	30.614,96	0,2627	1,0186	4.839,08

Os rótulos finais do K-Means foram avaliados também com Manhattan e Cosine. As silhouettes foram 0,2568 com distância Euclidiana, 0,2415 com Manhattan e 0,4130 com Cosine. A maior silhouette com Cosine não altera a escolha do algoritmo, pois o K-Means treinado otimiza inércia Euclidiana; essa comparação apenas mostra como a leitura de separação muda com a métrica.

Em amostra reprodutível de 6.000 registros, Agglomerative Average com distância Euclidiana obteve silhouette 0,7057, e DBSCAN com Manhattan obteve silhouette 0,5028, três clusters e cerca de 3,28% de ruído. Mesmo assim, a solução final manteve K-Means porque ele foi executado no conjunto completo e apresentou estabilidade muito alta: ARI mínimo de 0,996 e NMI mínimo de 0,992 nas sementes 0, 1, 2, 42 e 100.

Tabela 7: Distribuição e perfil médio dos clusters finais.

Cluster	Registros	%	Lat. média	Lon. média	Hora média	Hora pico
0	6.816	35,46	40,74722	-73,98437	16,73	17h
1	6.590	34,29	40,74735	-73,98705	17,41	17h
2	589	3,06	40,66811	-73,77651	14,96	18h
3	5.225	27,19	40,75074	-73,98301	7,25	7h

A leitura dos grupos combina posição, hora e dia. Os clusters 0 e 1 têm centros geográficos muito próximos, mas se separam principalmente pelo dia do mês: o cluster 1 domina o início do recorte, enquanto o cluster 0 domina os dias 11 a 16. O cluster 3 representa a atividade da manhã, com pico às 7h. O cluster 2 é menor, tem centro médio deslocado para uma região distante dos demais e concentra menos registros, o que motivou atenção especial na Etapa 4.

Tabela 8: Síntese interpretativa dos clusters.

Cluster	Interpretação principal
0	Grupo concentrado nos dias 11–16, principalmente tarde e noite, com centro próximo aos clusters densos de Manhattan.
1	Grupo concentrado nos dias 01–05, também forte em tarde e noite, indicando separação temporal em relação ao cluster 0.
2	Grupo pequeno, mais afastado geograficamente e com maior proporção de registros isolados no espaço-tempo.
3	Grupo associado ao período da manhã, com pico entre 6h e 8h e perfil temporal distinto dos demais.

Os mapas interativos gerados em `visualizacao/mapa_ny.html`, `visualizacao/mapa_clusters_ny.html` e `visualizacao/heatmap_ny.html` foram usados como apoio visual. Eles não substituem as métricas, mas ajudam a verificar se os agrupamentos e a densidade espacial fazem sentido quando projetados nas coordenadas originais.

6 Padrões, Regras e Anomalias

A Etapa 4 confirmou que os clusters não são apenas regiões geográficas: eles também codificam recortes temporais. Foram encontrados 88 itemsets frequentes e 17 regras após os filtros de confiança e lift. Os padrões mais importantes relacionam cluster, faixa do mês e período do dia.

Tabela 9: Principais padrões frequentes e regras de associação.

Padrão ou regra	Suporte	Confiança	Lift
<code>cluster=0 + faixa_dia=11-16</code>	25,38%	–	–
<code>cluster=1 + faixa_dia=01-05</code>	21,83%	–	–
<code>cluster=3 + periodo=manha</code>	19,32%	–	–
<code>periodo=manha → cluster=3</code>	19,32%	83,25%	3,06
<code>faixa_dia=01-05 + periodo=tarde → cluster=1</code>	10,47%	95,49%	2,79
<code>faixa_dia=11-16 + periodo=tarde → cluster=0</code>	13,32%	96,93%	2,73

As regras indicam que o cluster 3 está fortemente associado ao período da manhã, enquanto os clusters 1 e 0 separam, respectivamente, o início e o fim do período analisado em horários de tarde/noite. Essa leitura complementa a clusterização: os grupos finais devem ser entendidos como segmentos espaço-temporais, não apenas como áreas no mapa.

Um exemplo importante é a regra `periodo=manha → cluster=3`. Seu suporte de 19,32% significa que quase um quinto de todos os registros aparece simultaneamente no período da manhã e no cluster 3. A confiança de 83,25% indica que, entre os registros classificados como manhã, a grande maioria pertence ao cluster 3. O lift de 3,06 mostra que essa associação é mais de três vezes mais forte do que seria esperado se período e cluster fossem independentes. Portanto, a regra não apenas descreve uma frequência alta, mas evidencia uma relação consistente entre horário e agrupamento.

As regras envolvendo `faixa_dia=01-05` e `faixa_dia=11-16` ajudam a explicar por que os clusters 0 e 1 têm centros geográficos próximos, mas permanecem separados no modelo. O cluster 1 está associado ao início do período analisado, enquanto o cluster 0 aparece mais fortemente nos dias finais do recorte. Assim, a separação entre eles não deve ser interpretada apenas como diferença espacial: ela reflete a combinação entre localização, hora e dia.

Na detecção de anomalias, o limiar do percentil 97,5% da distância média aos 5 vizinhos foi 0,7116. Foram marcados 481 registros, equivalentes a 2,50% da amostra. O cluster 2 concentrou 160 anomalias, isto é, 27,16% de seus próprios registros, muito acima dos demais clusters. Isso reforça a interpretação de que ele representa um grupo pequeno, espacialmente afastado e menos denso.

Tabela 10: Anomalias por cluster na Etapa 4.

Cluster	Registros	Anomalias	% no cluster
0	6.816	81	1,19
1	6.590	90	1,37
2	589	160	27,16
3	5.225	150	2,87

7 Discussão e Conclusões

O projeto formou um fluxo coerente entre as quatro etapas. A Etapa 1 produziu uma base limpa e reprodutível; a Etapa 2 mostrou concentração temporal, baixa redundância e ausência de redução dimensional forte; a Etapa 3 selecionou uma clusterização estável e executável no conjunto completo; e a Etapa 4 traduziu os clusters em padrões, regras e anomalias interpretáveis.

A principal conclusão é que a demanda do recorte não é uniforme no tempo. O pico às 17h e a concentração entre 14h e 19h indicam maior atividade no fim da tarde e início da noite. Também há estrutura temporal dentro dos clusters: manhã se associa ao cluster 3, começo do recorte ao cluster 1 e final do recorte ao cluster 0. O cluster 2, menor e mais afastado, concentra a maior taxa de anomalias.

As limitações devem ser consideradas na interpretação. O projeto usa apenas os 20.000 primeiros registros do arquivo, cobre 01/05/2014 a 16/05/2014, contém somente a base B02512 e registra pontos de coleta sem destino, duração ou tarifa. Além disso, *Lat* e *Lon* foram normalizadas separadamente, de modo que as distâncias de modelagem não equivalem diretamente a quilômetros. Como próximos passos, recomenda-se usar distâncias geográficas reais, testar HDBSCAN, segmentar modelos por faixa horária e incorporar variáveis externas como clima, calendário, eventos e zonas administrativas.

Mesmo com essas limitações, o fluxo é coerente para uma análise descritiva. A escolha de manter variáveis temporais na clusterização foi confirmada pela baixa preservação de vizinhança quando se compara o espaço puramente geográfico com o espaço completo. A escolha de preservar outliers também se mostrou relevante, pois a Etapa 4 identificou que parte dos pontos isolados se concentra justamente no cluster menor e geograficamente mais afastado. Portanto, as decisões tomadas nas etapas iniciais influenciaram diretamente a capacidade de interpretar padrões raros no final do projeto.

Referências

- [1] FIVETHIRTYEIGHT. *Uber TLC FOIL Response*. GitHub, 2015. Disponível em: <https://github.com/fivethirtyeight/uber-tlc-foil-response>. Acesso em: 9 jul. 2026.
- [2] NEW YORK CITY TAXI & LIMOUSINE COMMISSION. *Taxi & Limousine Commission*. Disponível em: <https://www.nyc.gov/site/tlc/index.page>. Acesso em: 9 jul. 2026.
- [3] PEDREGOSA, Fabian et al. *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, v. 12, n. 85, p. 2825–2830, 2011.
- [4] HARRIS, Charles R. et al. *Array programming with NumPy*. Nature, v. 585, p. 357–362, 2020.
- [5] VIRTANEN, Pauli et al. *SciPy 1.0: fundamental algorithms for scientific computing in Python*. Nature Methods, v. 17, p. 261–272, 2020.
- [6] RASCHKA, Sebastian. *MLxtend: Providing machine learning and data science utilities and extensions to Python's scientific computing stack*. Journal of Open Source Software, v. 3, n. 24, 2018.
- [7] MCKINNEY, Wes. *Data Structures for Statistical Computing in Python*. Proceedings of the 9th Python in Science Conference, 2010.
- [8] PYTHON VISUALIZATION. *Folium documentation*. Disponível em: <https://python-visualization.github.io/folium/latest/>. Acesso em: 9 jul. 2026.