

Mobilidade Urbana Inteligente

Análise de Corridas da Uber em NY (Maio 2014)

Integrantes: João Vitor Dantas Barbosa, Matheus Gualter Silva Resende, Paulo Daniel Forti da Fonseca, Pedro Emilio Castro Lemos, Pedro Henrique Lopes Duarte

O Desafio da Mobilidade

Compreendendo padrões espaço-temporais através de dados reais

Contexto e Base de Dados

- A base analisada corresponde a corridas do serviço Uber na cidade de Nova York.
- Recorte temporal estabelecido de 1o a 16 de maio de 2014, selecionado a partir dos primeiros 20.000 registros originais.
- Após o rigoroso processo de limpeza e remoção de duplicatas, mantivemos 19.220 registros válidos.
- As variáveis ativas utilizadas na modelagem e exploração incluem: Latitude, Longitude, Hour (Hora) e Day (Dia).



Destques Metodológicos



Pré-processamento

Remoção de 780 duplicatas, criação de variáveis temporais (Hour, Day) e normalização das variáveis contínuas com Min-Max Scaling.



Identificação de Outliers

Utilização do critério do Intervalo Interquartil (IQR) para avaliar dispersão extrema, concentrada principalmente no espaço geográfico.



Análise PCA

A projeção validou que preservar 90% da variância exige todas as 4 componentes, indicando a importância de cada atributo original.

Avaliação e Modelagem

Correlação e Vizinhança

Nenhuma variável atingiu limiar crítico de redundância nos testes de Pearson e Spearman. A inclusão temporal (Hour e Day) alterou criticamente a proximidade; apenas 3,13% dos vizinhos eram exclusivamente espaciais.

Seleção de Algoritmos

Apesar de Agglomerative Clustering e DBSCAN apresentarem bons índices na amostra reduzida, o algoritmo **K-Means** prevaleceu como solução final devido à sua escalabilidade na base completa.

Principais Achados

Resultados da distribuição temporal e clusterização de passageiros


Concentração Temporal

43,6%

das corridas entre 14h e 19h

- **O Horário de Pico:** O maior volume diário de viagens foi inequivocamente registrado no fim da tarde, atingindo o máximo de demanda às 17h (8,44% de toda a amostra).
- **A Madrugada:** Em forte contraste, a atividade despenca vertiginosamente. O período que se estende da meia-noite (0h) às 5h concentra apenas uma fração de 6,05% das solicitações totais.

Perfil dos Clusters (K-Means)



- Cluster 0 (35,46%) - Pico às 17h
- Cluster 1 (34,29%) - Pico às 17h
- Cluster 3 (27,19%) - Pico às 7h
- Cluster 2 (3,06%) - Afastado (Pico 18h)

A solução revelou que a demanda é altamente concentrada no espaço. Três clusters volumosos dominam o fluxo das regiões centrais, enquanto o pequeno Cluster 2 representa uma demanda espacialmente distante e minoritária.

Regras de Associação e Padrões Frequentes



Metodologia Apriori

Aplicação do algoritmo Apriori para extrair regras diretas sobre as variáveis espaço-temporais previamente categorizadas (dia, hora, cluster).



Métricas de Corte

Filtros rigorosos para garantir regras de alta relevância:

Suporte $\geq 8\%$, Confiança $\geq 55\%$ e Lift $> 1,05$.




Principais Achados

As regras mais fortes revelaram uma marcante interdependência entre a faixa do fim da tarde/noite e a demanda nos clusters centrais de Manhattan.

Detecção Avançada de Anomalias (Outliers)

- **Abordagem por Distância (K-NN):** Em vez de limites unidimensionais, calculamos a distância média Euclidiana para os 5 vizinhos mais próximos no espaço 4D (Lat, Lon, Hour, Day).
- **Definição do Limiar Crítico:** Estabelecemos o percentil de **97,5 %** das maiores distâncias como ponto de corte definitivo.
- **Interpretação Prática:** Os pontos identificados revelam corridas anômalas (ex: viagens longas de madrugada). Nem todo outlier é ruído, mas sim uma demanda rara.



Justificativas da Modelagem Final

Variáveis e Clusterização

A manutenção de 4 variáveis baseou-se na validação do PCA. A escolha estatística de manter **K = 4** equilibrou a coesão matemática interna com a capacidade de interpretar geograficamente os fluxos da cidade.

Algoritmos e Métricas


O **Apriori** traduziu eficientemente interações complexas em regras. A métrica de **Distância Média K-NN** foi vital por correlacionar localização e horário, achando anomalias no relógio e no espaço simultaneamente.

Principais Limitações

Área Analítica	Limitação Identificada no Relatório	Impacto Estimado
Amostragem	Uso exclusivo dos 20.000 primeiros registros da base.	Pode ocultar variações presentes no restante da base completa.
Cobertura Temporal	Período de avaliação restrito de 01 a 16 de maio de 2014.	O modelo não captura a sazonalidade completa do mês ou ano.
Métricas Espaciais	Lat e Lon foram normalizadas separadamente no processo.	As distâncias calculadas no espaço de features não equivalem a quilômetros reais.
Correlações Globais	Análise limitou-se ao cálculo de métricas globais simples.	Essa abordagem genérica pode mascarar padrões locais por bairro.

Conclusões e Próximos Passos

- O projeto construiu um fluxo reprodutível para a análise de mobilidade urbana baseada em dados.
- A demanda revelou-se concentrada geograficamente e temporalmente, com claro pico de acionamento às 17h nas zonas centrais.
- Como próximos passos, recomenda-se explorar distâncias reais em quilômetros (Haversine) em vez de euclidiana normalizada.
- Recomenda-se também incorporar variáveis climáticas e de eventos da cidade para desenvolver um modelo preditivo mais robusto.



Perguntas?


Agradecemos pela atenção durante a apresentação.

Image Sources



http://googleusercontent.com/image_collection/image_retrieval/1021480130999037254_0

Source: Image Search



http://googleusercontent.com/image_collection/image_retrieval/9187471601207258827_0

Source: Image Search



http://googleusercontent.com/image_collection/image_retrieval/18230186927393361979_0


Source: Image Search

Image Sources



<http://publish.illinois.edu/imageofresearch/files/2026/02/Talimage.jpg>

Source: publish.illinois.edu



https://ladal.edu.au/tutorials/data_viz_intro/data_viz_intro_files/figure-html/anscombe_plot-1.png

Source: ladal.edu.au



https://media.istockphoto.com/id/2154887234/photo/futuristic-digital-network-background-people-and-cloud-computing-with-connections-technology.jpg?s=612x612&w=0&k=20&c=mZ9e-TfDny-WfCM9R_wCc8dMNRfcLoWEbqplGWygdlk=

Source: www.istockphoto.com